Análisis de Dataset

IntegraTrip · Tarea 3 · Traveling Magazine · versión reproducible local

7366	21	3.645.377	7366
chunks	ediciones	caracteres	IDs únicos

1. Alcance y metodología

El corpus reúne las 21 ediciones disponibles de Traveling Magazine, desde la 58 hasta la 78. Cada PDF se procesó con Docling sin OCR, HybridChunker y el tokenizer sentence-transformers/all-MiniLM-L6-v2. Los JSONL contienen texto contextualizado, revista, encabezados y páginas; los PDF originales permanecen fuera del repositorio.

Ediciones	58–78 (21 completas)
Chunks	7366
Rango de páginas	1–128
IDs duplicados	0
Grupos de texto exactamente duplicado	29
Chunks potencialmente editoriales/ruidosos	152

2. Temas, destinos y estructura

La vista de Atlas muestra una estructura con múltiples agrupaciones temáticas. Se observan etiquetas como Spanish Gastronomy Magazine, Beaches Spain, Spanish Villages, Portuguese Wine Tourism, Andalusian History, Japanese Cuisine, Rural Tourism Argentina, African Safari, Island Travel, Japanese Tea y Armenian Wine. Los términos locales dominantes complementan esta lectura: ciudad, historia, cocina, hotel, restaurante, vino, experiencia, cultura, gastronomía, naturaleza, museo y arquitectura.

Término	Apariciones
ciudad	1425
historia	1158
cocina	873
hotel	834
restaurante	798
solo	744
vino	743
lugar	742
experiencia	740
está	682
mundo	593
tradición	585

Destinos observables en encabezados

Entre los encabezados recurrentes aparecen Costa Rica, Estados Unidos, Colombia, México, Argentina, Suiza/Interlaken, Marrakech, Belfast, Innsbruck, Galicia, Alentejo, Zaragoza, Letur, Zamora y el Luberon. Esto muestra una mezcla de destinos internacionales y rutas regionales españolas.

Estructura editorial

Bienvenido a bordo	72
VIAJES	67
HISTORIA, ARTE Y CULTURA	50
Colaboran	46
ENOTURISMO	41
RESTAURANTES PROBADOS	35
LA VENTANA DE MANENA	32
VIAJES DE AUTOR	30
BODEGAS CON ALMA	27
LUGARES PARA SOÑAR	26
CONTENIDOS	25
Cómo llegar	23

3. Preguntas de exploración

Esta sección registra la inspección visual realizada sobre el mapa público de Atlas. Las etiquetas y fragmentos descritos corresponden a la vista del mapa; la auditoría local se usa sólo para complementar duplicados y cobertura.

¿Qué temas aparecen?

Viajes y destinos, historia, arte y cultura, gastronomía, vinos y enoturismo, restaurantes, hoteles, naturaleza, arquitectura y experiencias locales. Atlas también etiqueta agrupaciones específicas como Spanish Gastronomy Magazine, Japanese Cuisine, Portuguese Wine Tourism y African Safari.

¿Qué destinos aparecen?

Aparecen destinos de España y de otros países: Beaches Spain, Spanish Villages, Andalusian History, Rural Tourism Argentina, Japanese Tea, Marrakech, Belfast, Innsbruck, Costa Rica, México, Colombia, Argentina y Suiza, entre otros.

¿Hay clusters?

Sí. La proyección muestra clusters visualmente separados y etiquetas temáticas, incluyendo gastronomía española, playas de España, pueblos españoles, turismo vitivinícola portugués, historia andaluza, cocina japonesa y turismo rural argentino. También aparecen grupos más aislados, como Theme Parks Orlando y Jamaican Reggae Culture.

¿Hay chunks duplicados?

No hay IDs duplicados. La auditoría local encontró 29 grupos de texto exactamente repetido (256 chunks). La captura del mapa no muestra la capa de duplicados, por lo que no se afirma que Atlas los haya marcado visualmente.

¿Hay chunks irrelevantes?

Sí. La búsqueda playas devolvió un resultado con los temas Magazine Publishing y Executive Leadership y el encabezado DIRECTORA, incluyendo un correo editorial; es ruido para preguntas de viaje. Esto coincide con los 152 chunks locales marcados como potencialmente editoriales.

4. Consultas de prueba

Las capturas de Atlas muestran 369 resultados para cada consulta, equivalentes al 5,01% superior de la proyección. Los umbrales y ejemplos siguientes fueron observados directamente en el mapa.

Consulta	Resultados	Umbral	Observación
playas	369	0.59781	Beaches Spain + ruido editorial (DIRECTORA)
castillos	369	0.61005	ruta/patrimonio y turismo de naturaleza; relevancia parcial
comida romántica	369	0.55632	La Casa Romántica; gastronomía pertinente

Interpretación

playas recuperó puntos relacionados con Beaches Spain, pero también mostró ruido editorial. castillos recuperó contenido de turismo de naturaleza y una ruta con catedral; es una coincidencia patrimonial parcial, no una respuesta exclusivamente sobre castillos. comida romántica recuperó el tema Spanish Gastronomy / Culinary Events y el encabezado La Casa Romántica, con una coincidencia claramente pertinente.

Estado de Atlas

El dataset ya fue publicado en Atlas con Projection ID fa545497-39bc-4f71-bbd8-a966e93d396e. Dataset: https://atlas.nomic.ai/data/maximiliano/integratrip-traveling-rag. Mapa: https://atlas.nomic.ai/data/maximiliano/integratrip-traveling-rag/map. La inspección visual de clusters, etiquetas y búsquedas solicitadas se realizó con las capturas entregadas; la capa específica de duplicados no se confirmó visualmente y se reporta mediante la auditoría local.

5. Reproducibilidad y próximos pasos

Para regenerar este informe desde cero:

1. Descargar las ediciones 58–78 con scripts/rag/download_magazines.py.
2. Parsear con scripts/rag/parse_magazines.py.
3. Validar con scripts/rag/validate_chunks.py.
4. Analizar y generar este PDF con scripts/rag/analyze_corpus.py.
5. Crear el dataset Atlas con scripts/rag/upload_nomic.py y registrar en README el identificador y la URL pública.

Criterio de seguridad

La API key de Nomic sólo se lee desde el entorno del proceso server-side. No se guarda en el repositorio, no se incluye en el cliente ni se transmite al proxy LLM.

Conclusión

La etapa local del RAG está completa y el dataset está publicado. Queda integrar la nueva projection_id en Render, probar el chat público y mantener el criterio de rechazo cuando Atlas no entregue evidencia suficiente.